



9°

Limpieza de datos — el oficio del archivero

Guía 27-9-TIC

Período 3 · Datos — del registro al insight

Institución Educativa Sor María Juliana

Autor: Dr. Álvaro Cárdenas Orozco

Metodología MILC · Apertura ancestral · Pensamiento computacional · Triángulo Dussel-Estoicismo-Floridi

Producto: 1 dataset "sucio" (provisto por el docente o descargado de un portal abierto) limpiado por el estudiante con duplicados eliminados, formatos normalizados, vacíos corregidos y errores señalados, acompañado de bitácora de qué se cambió y por qué

Apertura: Limpieza de datos — el oficio del archivero

Saber ancestral

La **criba de granos** antes de cocinar — separar la semilla buena de la mala, de las piedras, del polvo, de las cáscaras vacías — es el mismo gesto que limpiar datos. Sin esa criba, lo que cocinas se daña; sin limpieza de datos, lo que concluyes es falso. La **abuela campesina de Bolívar Valle** y de las veredas de Cartago cribaba arroz una hora antes de cocinarlo, separando cada piedrita con la mano. La **partera Embera** del Chocó y del Risaralda escogía hojas, raíces y semillas una a una antes de preparar la medicina. El **archivero del pueblo** verificaba folio por folio antes de archivar. El **ordeñador valluno** colaba la leche antes de envasarla. Todos compartían la misma sabiduría: *lo que entra contaminado, sale contaminado*.

Saber contemporáneo

La **limpieza de datos** (*data cleaning*) es la operación más laboriosa y más subestimada del análisis. Antes de filtrar, pivotar o graficar, el dataset debe estar limpio: (1) sin **duplicados** (filas repetidas); (2) con **formatos normalizados** (fechas, mayúsculas, espacios); (3) sin **vacíos sospechosos** (celdas en blanco que deberían tener valor); (4) sin **errores tipográficos** (“9A” vs “9a” vs “9 A”). Una regla del oficio: *el 70 % del tiempo de un analista se va en limpiar; el 30 % en analizar*. Y la **bitácora** (registro de qué se cambió y por qué) es lo que separa al profesional del que solo “arregla y borra”.

Pregunta-puente

¿Cómo sabía la abuela que un grano estaba dañado sin probarlo? ¿Y qué pierde un analista novato cuando entrega un análisis “rápido y bonito” sin haber cribado antes los datos sucios?

Saber y saber hacer

Al terminar podrás: (1) **identificar** los 4 tipos de suciedad típica en un dataset (duplicados, formato, vacíos, errores); (2) **analizar** qué tipo de suciedad tiene tu dataset y cuál de las decisiones futuras corre más riesgo; (3) **evaluar** qué celdas se corrigen, cuáles se eliminan y cuáles se marcan como “revisar”; (4) **aplicar** la limpieza con una bitácora que documente cada cambio.

Autor	Dr. Álvaro Cárdenas Orozco
DBA	Tratamiento y visualización honesta de datos para la toma de decisiones (MEN, T&I)
Referentes	Ética del dato · Visualización honesta · Pensamiento computacional
Producto final	1 dataset “sucio”(provisto por el docente o descargado de un portal abierto) limpiado por el estudiante con duplicados eliminados, formatos normalizados, vacíos corregidos y errores señalados, acompañado de bitácora de qué se cambió y por qué

□ *Antes de empezar, mira el viaje completo. Hasta aquí trabajaste sobre tu propia tabla limpia. Hoy recibes una tabla sucia (de alguien más, descargada de un portal abierto, simulada por el docente). Es la prueba realista: en el mundo profesional, los datos casi nunca llegan limpios. Limpiar es el oficio invisible.*

Ruta MILC: así vamos a aprender

1

Escuta
Observo, escucho
y pregunto.

2

Sistematización
Pensamiento
computacional.

3

Praxis
Construyo y aplico.

4

Evaluación
Reflexión liberadora.

□ *Antes de teorizar, vas a abrir el dataset sucio y vas a descubrir las trampas sin instrucción previa. Cuántos duplicados hay, cuántas fechas mal escritas, cuántas celdas vacías sospechosas. El reconocimiento del problema es la primera mitad de la solución.*

Fase 1 · Escuta

Escena para escuchar

Actividad 1 · IDENTIFICA — Descubre la suciedad (15 min · individual). El docente reparte un dataset sucio de 50 filas. Sin instrucción específica, abre el archivo y *busca*: ¿cuántos duplicados ves?, ¿cuántas fechas con formato distinto?, ¿cuántas celdas vacías?, ¿cuántas inconsistencias de mayúscula/espacio? Anota cantidades y un ejemplo de cada tipo. **No corrijas todavía**: solo identifica. El reconocimiento es la mitad del oficio.

- ☐ Conté duplicados, formatos inconsistentes, vacíos y errores tipográficos.
- ☐ Anoté al menos 1 ejemplo concreto de cada tipo de problema.
- ☐ Resistí la tentación de “arreglar de una” y solo identifiqué.

Lo que va al cuaderno (Actividad 1 · IDENTIFICA). Título: «Actividad 1 — Descubre la suciedad». **Formato**: tabla 3 columnas (Tipo de problema | Cuántos casos | 1 ejemplo), 4 filas (uno por tipo: duplicados, formato, vacíos, errores). **Sabes que terminaste cuando** puedes nombrar dónde está cada tipo de suciedad sin tener que volver a buscar.

□ *Ya viste la suciedad. Ahora vamos a entender la **anatomía** de los 4 tipos de problema y a aprender la regla más importante: nunca limpies sin bitácora, porque sin bitácora nadie podrá reproducir tu análisis ni discutir tus decisiones.*

Fase 2 · Sistematización con pensamiento computacional

Cuatro pilares aplicados al tema

Los 4 tipos de suciedad piden tratamientos distintos. Vamos a descomponer cada uno con los pilares del pensamiento computacional para que sepas exactamente qué hacer con cada caso.

Pilar	Aplicación al tema
1. Descomposición	La suciedad se descompone así: (1) duplicados : filas que repiten información; tratamiento: <i>eliminar la copia, dejar el original con bitácora</i> . (2) Formato inconsistente : “2025-05-15” vs “15/05/2025”; tratamiento: <i>normalizar al formato estándar</i> . (3) Vacíos : celdas en blanco; tratamiento: <i>decidir si el vacío es legítimo, si se rellena con un valor por defecto, o si se marca como “faltante”</i> . (4) Errores tipográficos : “9A”, “9a”, “9 A”; tratamiento: <i>unificar con Buscar y reemplazar</i> .
2. Reconocimiento de patrones	Toda limpieza sigue el patrón “ identifica → decide → documenta ”: nunca corrijas sin haber decidido conscientemente qué hacer, y nunca decidas sin documentar. La bitácora tiene 4 columnas: <i>Qué encontré</i> / <i>Qué hice</i> / <i>Por qué</i> / <i>Cuántas celdas afectadas</i> . Sin bitácora, otro analista (o tú mismo en 2 meses) no puede reproducir tu trabajo.
3. Abstracción	Lo esencial cabe en una regla: <i>el original se conserva, la copia se limpia</i> . Nunca limpies sobre el archivo original. Duplica primero, renombra (“ <i>dataset_limpio_v1.xlsx</i> ”), trabaja sobre la copia. Si te equivocas, puedes volver al original sin haber perdido información. Esa disciplina simple evita el 90 % de los desastres de análisis.
4. Algoritmo conceptual	Algoritmo: (1) duplica el archivo y trabaja sobre la copia; (2) abre la bitácora antes de tocar nada; (3) atiende un tipo de problema a la vez (primero duplicados, después formato, después vacíos, después errores); (4) documenta cada cambio antes de pasar al siguiente; (5) guarda y verifica que la tabla siga teniendo el mismo número de columnas y el sentido original.

Anatomía de una bitácora bien hecha

Fecha: cuándo se hizo el cambio.

Qué encontré: 1 frase describiendo el problema.

Qué hice: 1 frase con la decisión tomada.

Por qué: 1 frase con el criterio que justifica la decisión.

Celdas afectadas: cuántas filas o casillas se modificaron.

Versión: v1, v2, v3 (a medida que avanza la limpieza).

Errores comunes y su corrección

(1) Borrar la suciedad sin documentar: nadie puede reproducir tu análisis. (2) Trabajar sobre el archivo original: si te equivocas, perdiste el dato crudo. (3) Eliminar filas con vacíos sin preguntar si el vacío era legítimo: “*sin teléfono*” puede ser un dato relevante, no un error. (4) Normalizar fechas “*a ojo*” sin verificar que la columna tenga formato de fecha real. (5) Confundir limpieza con *interpretación*: tu trabajo es dejar los datos limpios, no inventar valores donde no los hay.

Lo que va al cuaderno (Actividad 2 · ANALIZA). Título: «Actividad 2 — Anatomía de la limpieza». **Formato:** 4 fichas, una por tipo de suciedad, cada una con: qué es + cómo se detecta + cómo se trata + 1 error frecuente. **Sabes que terminaste cuando** podrías explicar a un compañero qué hacer frente a cada tipo de suciedad sin consultar.

□ Tienes el método. Toca aplicarlo: limpiar el dataset corrigiendo lo corregible, eliminando lo eliminable, marcando lo dudoso, y dejando una bitácora clara de cada cambio. El producto no es solo un archivo limpio: es un archivo limpio con historia documentada.

Fase 3 · Praxis con pensamiento computacional

Construyendo el producto con los cuatro pilares

Actividad 3 · APLICA — Limpia el dataset con bitácora (30 min · individual). Hora de aplicar. Vas a duplicar el archivo sucio, abrir la bitácora, y atender los 4 tipos de problema uno por uno, documentando cada cambio. Entregas el dataset limpio y la bitácora completa.

Pilar	Aplicación al producto
Descomposición	Tu trabajo se descompone en 5 piezas: (1) duplicado del archivo (<i>copia para limpiar</i>); (2) bitácora abierta antes de tocar nada; (3) limpieza de duplicados; (4) normalización de formatos; (5) tratamiento de vacíos y errores tipográficos. Cada paso con su entrada en la bitácora.
Patrones	Sigue el patrón “un tipo de problema a la vez” : no mezcles tareas. Termina los duplicados antes de pasar a formatos. Termina formatos antes de pasar a vacíos. Esa disciplina evita perder el hilo y deja una bitácora ordenada.
Abstracción	Cada entrada de bitácora expresa una sola decisión, no tres. Si combinas <i>“eliminé duplicados y normalicé fechas”</i> en una sola línea, otro lector no sabrá qué celdas fueron afectadas por cada cambio. Una decisión, una línea.
Algoritmo de armado	Algoritmo: (1) duplica archivo; (2) abre bitácora; (3) elimina duplicados → entrada en bitácora; (4) normaliza formatos → entrada en bitácora; (5) trata vacíos → entrada en bitácora; (6) corrige tipográficos → entrada en bitácora; (7) guarda como v_limpio.

Checklist antes de entregar el dataset limpio

- ☐ Archivo duplicado: trabajé sobre copia, no sobre original.
- ☐ Bitácora con al menos 4 entradas (una por tipo de problema).
- ☐ Cada entrada con qué, cómo, por qué, cuántas celdas.
- ☐ Dataset limpio tiene mismas columnas y sentido que el original.
- ☐ Un compañero podría reproducir mi limpieza leyendo solo la bitácora.

Plantilla de trabajo

Bitácora — Limpieza del dataset [nombre]

Fecha. 2026-05-XX.

Entrada 1 (duplicados). *Qué encontré + qué hice + por qué + celdas afectadas.*

Entrada 2 (formato). *Lo mismo.*

Entrada 3 (vacíos). *Lo mismo.*

Entrada 4 (tipográficos). *Lo mismo.*

Lo que va al cuaderno (Actividad 3 · APLICA). Título: «Actividad 3 — Bitácora de limpieza». **Formato:** 4 entradas (una por tipo) con qué + cómo + por qué + celdas afectadas. **Extensión:** 1 página de cuaderno. **Sabes que terminaste cuando** la bitácora permite que otro reproduzca el trabajo sin más explicación.

- ☐ *Lo que sigue resume qué entregas hoy: dataset limpio + bitácora. El criterio principal: que un compañero, leyendo solo tu bitácora, pueda entender qué hiciste y **por qué** en cada caso.*

Producto de la sesión

1 dataset limpio + bitácora completa con 4 entradas.

Criterios de calidad

(1) Archivo duplicado, original conservado intacto. (2) Bitácora con al menos 4 entradas (duplicados, formato, vacíos, tipográficos). (3) Cada entrada documenta qué, cómo, por qué y celdas afectadas. (4) Dataset limpio conserva las columnas y el sentido original. (5) Un compañero podría reproducir la limpieza leyendo solo la bitácora.

□ *Antes de cerrar, mira la limpieza desde las cinco dimensiones humanas. Limpiar bien es ética del análisis; limpiar sin bitácora es manipulación oculta.*

Fase 4 · Evaluación liberadora — cinco dimensiones

Sentido de la evaluación

Evaluar no es solo revisar una nota. Es reconocer qué aprendí, qué cambió en mí, qué emociones manejé, cómo me relaciono con la ciudad y la comunidad, y qué le dejaré a quien viene detrás.

Mi reflexión liberadora en cinco dimensiones. Completa cada frase iniciada:

Dimensión	Mi respuesta (frame starter)	Algo que descubrí
1. Personal	Lo que más cambió en mí fue _____	_____
2. Emocional	La emoción más fuerte fue _____ y la regulé _____	_____
3. Ciudadana	En democracia esto importa porque _____	_____
4. Local (Cartago)	En mi barrio sería útil para _____	_____
5. Intergeneracional	A mi abuela/abuelo le diría _____	_____

Para la próxima sustentación. Vuelve a esta tabla en seis meses. Verás que las respuestas cambian — no porque lo aprendido cambie, sino porque tú cambias. La evaluación liberadora es una conversación contigo a través del tiempo.

□ *Y para terminar, tres voces sobre limpiar. Dussel sobre lo que se descarta sin nombrarlo, Marco Aurelio sobre la paciencia del oficio invisible, Floridi sobre la integridad de los datos como condición de la verdad pública.*

Triángulo de pensamiento · cierre filosófico

Dussel · lente del nosotros

“Lo que se descarta sin nombrar deja de existir para quien lee el dato limpio.”

Cuando eliminas “duplicados” pero la fila duplicada en realidad era una segunda compra del mismo cliente, descartas información real. Cuando rellenas vacíos con “0” sin pensar, conviertes “no responde” en “responde cero”. La phronesis del analista exige nombrar siempre qué se descarta, qué se rellena y por qué, en la bitácora. Limpiar sin nombrar es manipular en silencio.

Cuando limpié, ¿qué decisiones tomé en silencio que un crítico podría discutir si las viera escritas? ¿Qué cambia si las nombro?

Estoicismo · Marco Aurelio · cuidado interior

“La paciencia del oficio invisible es la base de toda obra que dura.”

Es tentador saltar la limpieza para llegar rápido al análisis. La sabiduría estoica recomienda lo contrario: *quien apura la criba, dañará la cosecha*. El 70 % del tiempo en limpiar es regla del oficio, no defecto. Quien acepta esa paciencia entrena una virtud invisible que sustenta toda conclusión posterior.

¿Resistí la tentación de saltar limpieza para llegar al gráfico bonito? ¿Qué calidad ganan mis conclusiones al haber cribado primero?

Floridi · lente de la infoesfera

“La integridad de los datos es la condición de toda verdad pública contemporánea.”

Reportes de salud, indicadores económicos, métricas educativas: toda decisión pública contemporánea descansa en datos que alguien limpió antes. Quien limpia datos no hace tarea menor: protege la integridad de la infoesfera. Tu bitácora es el equivalente civil del cuaderno del archivero del pueblo.

¿Cuántas decisiones públicas leí esta semana sin preguntar quién limpió los datos detrás? ¿Qué garantía tengo de que esa limpieza tuvo bitácora?

Compromiso final

Criterio	Lo logré	En proceso	Necesito apoyo
Comprensión del tema	Explico ideas centrales con mis palabras.	Reconozco ideas pero falta precisión.	Necesito repasar conceptos base.
Pensamiento computacional	Apliqué los 4 pilares al diseñar mi producto.	Apliqué algunos pilares.	Necesito releer la fase 2.
Aplicación y producto	Mi producto cumple los criterios y se puede revisar.	Producto funcional con ajustes pendientes.	Aún en construcción.
Reflexión 5 dimensiones	Respondí cada dimensión con honestidad.	Respondí algunas con detalle.	Mis respuestas son muy generales.
Triángulo de pensamiento	Conecté las 3 voces con mi trabajo real.	Conecté al menos una.	No relaciono las voces con mi proceso.

Hoy entendí que:

Mi compromiso para la próxima sesión es:

Cita de despedida · Marco Aurelio

“El obstáculo en el camino se vuelve el camino. Lo que estorba al camino se vuelve camino.”
Cada error de hoy, bien observado, se convierte en pieza del camino que pisarás mañana.

Nombre completo: _____

Fecha: _____ **Curso/grupo:** _____

Mi firma: _____

Para la próxima semana. Toma una tabla cotidiana *ajena* (gastos del hogar, lista de asistencia de un grupo, libreta de un comerciante del barrio). Identifica los 4 tipos de suciedad y propón cómo la limpiarías **sin tocarla**. La phronesis se entrena también en ver el oficio antes de ejecutarlo.